

# Sprawozdanie z analizy poziomu przestępczości (Communities and Crime USA)

## 1. Cel projektu i opis problemu

Celem badania było stworzenie i ewaluacja modeli regresyjnych przewidujących poziom przestępczości z użyciem przemocy (ViolentCrimesPerPop) w społecznościach na terenie USA. Analiza obejmowała również badanie korelacji cech demograficznych (struktury etnicznej) z docelową zmienną oraz porównanie skuteczności 10 różnych podejść algorytmicznych.

## 2. Przygotowanie danych i preprocessing

Zgodnie z implementacją w kodzie, proces przygotowania danych przebiegał następująco:

- Wczytywanie danych  
Nazwy kolumn pobrano z pliku tekstowego communities.names, a właściwe dane z pliku communities.data (obsługując braki danych oznaczone jako ?).
- Selekcja cech  
Usunięto nieistotne kolumny administracyjne i identyfikacyjne: state, county, community, communityname, fold.
- Czyszczenie danych  
Zastosowano SimpleImputer ze strategią mediany do uzupełnienia brakujących wartości oraz dokonano jawnej konwersji typów na wartości numeryczne.
- Skalowanie  
Dla algorytmów wrażliwych na odległość i optymalizację gradientową (KNN, regresja liniowa, Ridge, Voting, Stacking, Sieć neuronowa) zastosowano StandardScaler.
- Podział danych  
Zbiór podzielono na część treningową i testową w proporcji 80/20 przy zachowaniu stałego punktu startowego (random\_state=42).

## 3. Metodologia i testowane modele

W eksperymencie sprawdzono wiele algorytmów uczenia maszynowego:

- Modele proste / liniowe  
Regresja liniowa, Regresja Ridge, K-Najbliższych Sąsiadów (KNN).
- Modele drzewiaste  
Pojedyncze drzewo decyzyjne, Random Forest, Gradient Boosting, Bagging.
- Modele złożone  
Sieć neuronowa (MLP z dwiema warstwami ukrytymi: 64 i 32 neurony) oraz zespoły modeli (Ensembles).

## 4. Analiza wyników i porównanie modeli

Wszystkie modele zostały ocenione na zbiorze testowym za pomocą miary RMSE (błąd średniokwadratowy). Poniższa tabela przedstawia zestawienie modeli od najlepszego (najniższe RMSE) do najgorszego:

| Pozycja | Model                | RMSE   |
|---------|----------------------|--------|
| 1       | Voting               | 0.1322 |
| 2       | Stacking             | 0.1325 |
| 3       | Ridge                | 0.1345 |
| 4       | Regresja liniowa     | 0.1346 |
| 5       | Random Forest        | 0.1352 |
| 6       | Bagging              | 0.1352 |
| 7       | Gradient Boosting    | 0.1387 |
| 8       | KNN                  | 0.1441 |
| 9       | Sieć neuronowa (MLP) | 0.1611 |
| 10      | Drzewo decyzyjne     | 0.1700 |

Zgrupowany model Voting, łączący estymatory KNN, Ridge i regresji liniowej, osiągnął najlepsze parametry dopasowania:

- MAE (Średni błąd bezwzględny): 0.0906
- RMSE (Pierwiastek błędu średniokwadratowego): 0.1322
- $R^2$  (Współczynnik determinacji): 0.6350 (model wyjaśnia około 63.5% wariancji zmiennej celu)

## 5. Analiza korelacji demograficznych

W ramach analizy zbadano liniowy współczynnik korelacji Pearsona pomiędzy procentowym udziałem poszczególnych grup etnicznych w populacji społeczności a wskaźnikiem przestępczości (ViolentCrimesPerPop). Wyniki prezentują się następująco:

- Biali (racePctWhite): -0.68 — silna korelacja ujemna. Oznacza to, że wyższy odsetek tej grupy w danej społeczności statystycznie współwystępuje z niższym poziomem przestępczości.
- Czarni (racePctBlack): 0.63 — silna korelacja dodatnia. Wyższy odsetek tej grupy w danej społeczności wiąże się ze statystycznie wyższym wskaźnikiem przestępczości w zbiorze danych.
- Latynosi (racePctHispanic): 0.29 — słaba/umiarkowana korelacja dodatnia.
- Azjaci (racePctAsian): 0.04 — brak istotnej korelacji liniowej z poziomem przestępczości.

## 6. Wnioski

1. Najwyższą stabilność predykcji wykazują modele zespołowe (Voting) oraz klasyczne modele liniowe z regularyzacją (Ridge).
2. Słaba wydajność sieci neuronowej (MLP) i pojedynczego drzewa decyzyjnego sugeruje, że domyślne parametry tych struktur wymagają tuningu hiperparametrów (np. doboru silniejszej regularyzacji lub zmiany architektury sieci), aby uniknąć przeuczenia.
3. Zbiór charakteryzuje się wyraźnymi korelacjami liniowymi pomiędzy strukturą demograficzną a zmienną objaśnianą, co sprawia, że algorytmy bazujące na relacjach liniowych (Ridge/Regresja liniowa) radzą sobie w tym zadaniu bardzo dobrze.